```
import io #modulo para realizar distintas operaciones en Python.
In [1]:
        import pandas as pd #Librería de análisis de datos.
        import matplotlib.pyplot as plt #Libraría de representación de gráficas.
        import seaborn as sb #Herramienta de visualización de datos.
        import numpy as np #Numpy facilita un largo set de tipos de datos numéricos pa
        ra construir arrays.
        from scipy.stats import norm #Librería con herramientas y algoritmos matemátic
        os.
        from scipy import stats
        from sklearn import svm #Librería con algoritmos de aprendizaje
        from sklearn.preprocessing import StandardScaler
        from sklearn.model selection import train test split
        from sklearn.metrics import r2 score, mean squared error
        from sklearn.neural network import MLPRegressor
        from sklearn.preprocessing import LabelEncoder
        from sklearn.svm import OneClassSVM
        from sklearn.cluster import DBSCAN
        from pylab import rcParams
        from sklearn.ensemble import IsolationForest
        from sklearn.preprocessing import StandardScaler
        from sklearn.decomposition import PCA
        from sklearn import metrics
        from sklearn.preprocessing import MinMaxScaler
```

Lectura de datos

```
In [2]:
        #Read CSV
        wdbc = pd.read csv(
            'wdbc.data',
            encoding='utf-8',
            delim whitespace=False,
            names=["id","diagnostic",'mean radius', 'mean texture', 'mean perimter',
         'mean area', 'mean smoothnesss', 'mean compactness', 'mean concavity', 'mean c
        oncave points', 'mean symetry', 'mean fractal dimension', 'se radius', 'se textu
        re', 'se perimter', 'se area', 'se smoothnesss', 'se compactness', 'se concavi
        ty', 'se concave points', 'se symetry', 'se fractal dimension' worst radius',
         'worst texture', 'worst perimter', 'worst area', 'worst smoothnesss', 'worst c
        ompactness', 'worst concavity', 'worst concave points', 'worst symetry', 'worst
        fractal dimension'],
            index col=False,
            header=None,
        display(wdbc)
```

	id	diagnostic	mean radius	mean texture	mean perimter	mean area	mean smoothnesss	mean compactness	m conca
0	842302	М	17.990	10.38	122.80	1001.0	0.11840	0.27760	0.300
1	842517	М	20.570	17.77	132.90	1326.0	0.08474	0.07864	0.086
2	84300903	M	19.690	21.25	130.00	1203.0	0.10960	0.15990	0.197
3	84348301	M	11.420	20.38	77.58	386.1	0.14250	0.28390	0.241
4	84358402	M	20.290	14.34	135.10	1297.0	0.10030	0.13280	0.198
5	843786	M	12.450	15.70	82.57	477.1	0.12780	0.17000	0.157
6	844359	M	18.250	19.98	119.60	1040.0	0.09463	0.10900	0.112
7	84458202	М	13.710	20.83	90.20	577.9	0.11890	0.16450	0.093
8	844981	M	13.000	21.82	87.50	519.8	0.12730	0.19320	0.185
9	84501001	М	12.460	24.04	83.97	475.9	0.11860	0.23960	0.227
10	845636	М	16.020	23.24	102.70	797.8	0.08206	0.06669	0.032
11	84610002	M	15.780	17.89	103.60	781.0	0.09710	0.12920	0.099
12	846226	M	19.170	24.80	132.40	1123.0	0.09740	0.24580	0.206
13	846381	M	15.850	23.95	103.70	782.7	0.08401	0.10020	0.099
14	84667401	М	13.730	22.61	93.60	578.3	0.11310	0.22930	0.212
15	84799002	M	14.540	27.54	96.73	658.8	0.11390	0.15950	0.163
16	848406	М	14.680	20.13	94.74	684.5	0.09867	0.07200	0.073
17	84862001	М	16.130	20.68	108.10	798.8	0.11700	0.20220	0.172
18	849014	M	19.810	22.15	130.00	1260.0	0.09831	0.10270	0.147
19	8510426	В	13.540	14.36	87.46	566.3	0.09779	0.08129	0.066
20	8510653	В	13.080	15.71	85.63	520.0	0.10750	0.12700	0.045
21	8510824	В	9.504	12.44	60.34	273.9	0.10240	0.06492	0.029
22	8511133	M	15.340	14.26	102.50	704.4	0.10730	0.21350	0.207
23	851509	M	21.160	23.04	137.20	1404.0	0.09428	0.10220	0.109
24	852552	М	16.650	21.38	110.00	904.6	0.11210	0.14570	0.152
25	852631	М	17.140	16.40	116.00	912.7	0.11860	0.22760	0.222
26	852763	М	14.580	21.53	97.41	644.8	0.10540	0.18680	0.142
27	852781	M	18.610	20.25	122.10	1094.0	0.09440	0.10660	0.149
28	852973	М	15.300	25.27	102.40	732.4	0.10820	0.16970	0.168
29	853201	М	17.570	15.05	115.00	955.1	0.09847	0.11570	0.098
539	921362	В	7.691	25.44	48.34	170.4	0.08668	0.11990	0.092
540	921385	В	11.540	14.44	74.65	402.9	0.09984	0.11200	0.067
541	921386	В	14.470	24.99	95.81	656.4	0.08837	0.12300	0.100

	id	diagnostic	mean radius	mean texture	mean perimter	mean area	mean smoothnesss	mean compactness	m conca
542	921644	В	14.740	25.42	94.70	668.6	0.08275	0.07214	0.041
543	922296	В	13.210	28.06	84.88	538.4	0.08671	0.06877	0.029
544	922297	В	13.870	20.70	89.77	584.8	0.09578	0.10180	0.036
545	922576	В	13.620	23.23	87.19	573.2	0.09246	0.06747	0.029
546	922577	В	10.320	16.35	65.31	324.9	0.09434	0.04994	0.010
547	922840	В	10.260	16.58	65.85	320.8	0.08877	0.08066	0.043
548	923169	В	9.683	19.34	61.05	285.7	0.08491	0.05030	0.023
549	923465	В	10.820	24.21	68.89	361.6	0.08192	0.06602	0.015
550	923748	В	10.860	21.48	68.51	360.5	0.07431	0.04227	0.000
551	923780	В	11.130	22.44	71.49	378.4	0.09566	0.08194	0.048
552	924084	В	12.770	29.43	81.35	507.9	0.08276	0.04234	0.019
553	924342	В	9.333	21.94	59.01	264.0	0.09240	0.05605	0.039
554	924632	В	12.880	28.92	82.50	514.3	0.08123	0.05824	0.061
555	924934	В	10.290	27.61	65.67	321.4	0.09030	0.07658	0.059
556	924964	В	10.160	19.59	64.73	311.7	0.10030	0.07504	0.005
557	925236	В	9.423	27.88	59.26	271.3	0.08123	0.04971	0.000
558	925277	В	14.590	22.68	96.39	657.1	0.08473	0.13300	0.102
559	925291	В	11.510	23.93	74.52	403.5	0.09261	0.10210	0.111
560	925292	В	14.050	27.15	91.38	600.4	0.09929	0.11260	0.044
561	925311	В	11.200	29.37	70.67	386.0	0.07449	0.03558	0.000
562	925622	М	15.220	30.62	103.40	716.9	0.10480	0.20870	0.255
563	926125	М	20.920	25.09	143.00	1347.0	0.10990	0.22360	0.317
564	926424	M	21.560	22.39	142.00	1479.0	0.11100	0.11590	0.243
565	926682	М	20.130	28.25	131.20	1261.0	0.09780	0.10340	0.144
566	926954	M	16.600	28.08	108.30	858.1	0.08455	0.10230	0.092
567	927241	M	20.600	29.33	140.10	1265.0	0.11780	0.27700	0.351
568	92751	В	7.760	24.54	47.92	181.0	0.05263	0.04362	0.000

569 rows × 31 columns


```
In [3]: #Separación de las columnas no utilizadas para crear un modelo
wdbc=wdbc.drop(['id', 'diagnostic'],axis=1)
```

Identificación de Anomalías - Isolation Forest

```
In [4]: #Modelo
    model=IsolationForest(n_estimators=100, max_samples=256, contamination=0.2, ma
    x_features=1.0, bootstrap=False, n_jobs=-1, random_state=2019,verbose=0, behav
    iour="new")
    model.fit(wdbc)
```

Out[4]: IsolationForest(behaviour='new', bootstrap=False, contamination=0.2, max_features=1.0, max_samples=256, n_estimators=100, n_jobs=-1, random state=2019, verbose=0)

Out[5]: (array([3., 3., 6., 7., 18., 41., 54., 115., 186., 136.]), array([-0.20259888, -0.17287623, -0.14315358, -0.11343094, -0.08370829, -0.05398565, -0.024263 , 0.00545965, 0.03518229, 0.06490494, 0.09462758]), <a list of 10 Patch objects>)



```
In [6]: #Labelizador según los resultados representados
    predwdbc=model.predict(wdbc)
    len(predwdbc)
    wdbc["label"]=predwdbc
    display(wdbc)
```

	mean radius	mean texture	mean perimter	mean area	mean smoothnesss	mean compactness	mean concavity	mean concave points	mear symetry
0	17.990	10.38	122.80	1001.0	0.11840	0.27760	0.300100	0.147100	0.2419
1	20.570	17.77	132.90	1326.0	0.08474	0.07864	0.086900	0.070170	0.1812
2	19.690	21.25	130.00	1203.0	0.10960	0.15990	0.197400	0.127900	0.2069
3	11.420	20.38	77.58	386.1	0.14250	0.28390	0.241400	0.105200	0.2597
4	20.290	14.34	135.10	1297.0	0.10030	0.13280	0.198000	0.104300	0.1809
5	12.450	15.70	82.57	477.1	0.12780	0.17000	0.157800	0.080890	0.2087
6	18.250	19.98	119.60	1040.0	0.09463	0.10900	0.112700	0.074000	0.1794
7	13.710	20.83	90.20	577.9	0.11890	0.16450	0.093660	0.059850	0.2196
8	13.000	21.82	87.50	519.8	0.12730	0.19320	0.185900	0.093530	0.2350
9	12.460	24.04	83.97	475.9	0.11860	0.23960	0.227300	0.085430	0.2030
10	16.020	23.24	102.70	797.8	0.08206	0.06669	0.032990	0.033230	0.1528
11	15.780	17.89	103.60	781.0	0.09710	0.12920	0.099540	0.066060	0.1842
12	19.170	24.80	132.40	1123.0	0.09740	0.24580	0.206500	0.111800	0.2397
13	15.850	23.95	103.70	782.7	0.08401	0.10020	0.099380	0.053640	0.1847
14	13.730	22.61	93.60	578.3	0.11310	0.22930	0.212800	0.080250	0.2069
15	14.540	27.54	96.73	658.8	0.11390	0.15950	0.163900	0.073640	0.2303
16	14.680	20.13	94.74	684.5	0.09867	0.07200	0.073950	0.052590	0.1586
17	16.130	20.68	108.10	798.8	0.11700	0.20220	0.172200	0.102800	0.2164
18	19.810	22.15	130.00	1260.0	0.09831	0.10270	0.147900	0.094980	0.1582
19	13.540	14.36	87.46	566.3	0.09779	0.08129	0.066640	0.047810	0.188ŧ
20	13.080	15.71	85.63	520.0	0.10750	0.12700	0.045680	0.031100	0.1967
21	9.504	12.44	60.34	273.9	0.10240	0.06492	0.029560	0.020760	0.181
22	15.340	14.26	102.50	704.4	0.10730	0.21350	0.207700	0.097560	0.2521
23	21.160	23.04	137.20	1404.0	0.09428	0.10220	0.109700	0.086320	0.1769
24	16.650	21.38	110.00	904.6	0.11210	0.14570	0.152500	0.091700	0.199ŧ
25	17.140	16.40	116.00	912.7	0.11860	0.22760	0.222900	0.140100	0.3040
26	14.580	21.53	97.41	644.8	0.10540	0.18680	0.142500	0.087830	0.2252
27	18.610	20.25	122.10	1094.0	0.09440	0.10660	0.149000	0.077310	0.1697
28	15.300	25.27	102.40	732.4	0.10820	0.16970	0.168300	0.087510	0.1926
29	17.570	15.05	115.00	955.1	0.09847	0.11570	0.098750	0.079530	0.1739
539	7.691	25.44	48.34	170.4	0.08668	0.11990	0.092520	0.013640	0.2037
540	11.540	14.44	74.65	402.9	0.09984	0.11200	0.067370	0.025940	0.1818
541	14.470	24.99	95.81	656.4	0.08837	0.12300	0.100900	0.038900	0.1872

	mean radius	mean texture	mean perimter	mean area	mean smoothnesss	mean compactness	mean concavity	mean concave points	mear symetry
542	14.740	25.42	94.70	668.6	0.08275	0.07214	0.041050	0.030270	0.1840
543	13.210	28.06	84.88	538.4	0.08671	0.06877	0.029870	0.032750	0.1628
544	13.870	20.70	89.77	584.8	0.09578	0.10180	0.036880	0.023690	0.1620
545	13.620	23.23	87.19	573.2	0.09246	0.06747	0.029740	0.024430	0.1664
546	10.320	16.35	65.31	324.9	0.09434	0.04994	0.010120	0.005495	0.1885
547	10.260	16.58	65.85	320.8	0.08877	0.08066	0.043580	0.024380	0.1669
548	9.683	19.34	61.05	285.7	0.08491	0.05030	0.023370	0.009615	0.1580
549	10.820	24.21	68.89	361.6	0.08192	0.06602	0.015480	0.008160	0.1976
550	10.860	21.48	68.51	360.5	0.07431	0.04227	0.000000	0.000000	0.1661
551	11.130	22.44	71.49	378.4	0.09566	0.08194	0.048240	0.022570	0.2030
552	12.770	29.43	81.35	507.9	0.08276	0.04234	0.019970	0.014990	0.153§
553	9.333	21.94	59.01	264.0	0.09240	0.05605	0.039960	0.012820	0.1692
554	12.880	28.92	82.50	514.3	0.08123	0.05824	0.061950	0.023430	0.1566
555	10.290	27.61	65.67	321.4	0.09030	0.07658	0.059990	0.027380	0.1593
556	10.160	19.59	64.73	311.7	0.10030	0.07504	0.005025	0.011160	0.1791
557	9.423	27.88	59.26	271.3	0.08123	0.04971	0.000000	0.000000	0.1742
558	14.590	22.68	96.39	657.1	0.08473	0.13300	0.102900	0.037360	0.1454
559	11.510	23.93	74.52	403.5	0.09261	0.10210	0.111200	0.041050	0.1388
560	14.050	27.15	91.38	600.4	0.09929	0.11260	0.044620	0.043040	0.1537
561	11.200	29.37	70.67	386.0	0.07449	0.03558	0.000000	0.000000	0.1060
562	15.220	30.62	103.40	716.9	0.10480	0.20870	0.255000	0.094290	0.2128
563	20.920	25.09	143.00	1347.0	0.10990	0.22360	0.317400	0.147400	0.2149
564	21.560	22.39	142.00	1479.0	0.11100	0.11590	0.243900	0.138900	0.1726
565	20.130	28.25	131.20	1261.0	0.09780	0.10340	0.144000	0.097910	0.1752
566	16.600	28.08	108.30	858.1	0.08455	0.10230	0.092510	0.053020	0.1590
567	20.600	29.33	140.10	1265.0	0.11780	0.27700	0.351400	0.152000	0.2397
568	7.760	24.54	47.92	181.0	0.05263	0.04362	0.000000	0.000000	0.1587

569 rows × 30 columns

Muestras Anómalas

```
In [7]: #Muestras anómalas
  outliers=wdbc.loc[wdbc["label"]==-1]
  outliers_index=list(outliers.index)
  print(outliers_index)
```

[0, 3, 4, 9, 12, 18, 22, 23, 24, 25, 33, 38, 42, 45, 59, 60, 61, 63, 68, 71, 72, 77, 78, 82, 83, 95, 101, 105, 108, 112, 116, 119, 122, 138, 140, 146, 15 1, 152, 161, 164, 175, 176, 178, 180, 181, 190, 192, 197, 202, 203, 210, 212, 213, 214, 219, 236, 237, 250, 252, 256, 257, 258, 259, 260, 265, 272, 288, 29 0, 300, 302, 307, 314, 318, 323, 339, 343, 351, 352, 366, 368, 369, 373, 376, 379, 382, 389, 391, 393, 400, 417, 424, 430, 461, 468, 473, 485, 489, 491, 50 3, 504, 505, 520, 521, 533, 538, 539, 557, 561, 562, 563, 564, 565, 567, 568]


```
In [8]: #Número de muestras normales y muestras anómalas
print(wdbc["label"].value_counts())
```

1 455 -1 114

Name: label, dtype: int64

Visualización

```
#Remover la etiqueta
In [9]:
        wdbc=wdbc.drop(["label"],axis=1)
        #Pasar las variables a dos dimensiones
        pca=PCA(2)
        pca.fit(wdbc)
        #Array tras la transformación con PCA
        principalDF=pd.DataFrame(data=pca.transform(wdbc), columns=["principal compone
        nt 1", "principal component 2"])
        #VaLores
        principalDF_values=principalDF.iloc[:,:].values
        #Visualización
        fig = plt.figure(figsize = (12,8))
        b1=plt.scatter(principalDF_values[:,0],principalDF_values[:,1], c='white',s=20
         ,edgecolor='k', label="Normal")
        b1=plt.scatter(principalDF_values[outliers_index,0],principalDF_values[outlier
        s index,1], s=20, c="red", label="outlier")
        plt.legend(loc="upper right")
        plt.show()
```



Comprobación resultados

```
wdbccomp = pd.read csv(
In [10]:
               'wdbc.data',
               encoding='utf-8',
               delim whitespace=False,
               names=["id","diagnostic",'mean radius', 'mean texture', 'mean perimter',
           'mean area', 'mean smoothnesss', 'mean compactness', 'mean concavity', 'mean c
          oncave points', 'mean symetry', 'mean fractal dimension', 'se radius', 'se textu re', 'se perimter', 'se area', 'se smoothnesss', 'se compactness', 'se concavi
          ty', 'se concave points', 'se symetry', 'se fractal dimension' worst radius',
           'worst texture', 'worst perimter', 'worst area', 'worst smoothnesss', 'worst c
          ompactness', 'worst concavity', 'worst concave points', 'worst symetry', 'worst
          fractal dimension'],
               index_col=False,
               header=None,
          )
          wdbccomp["label"]=predwdbc
          wdbccomp["label"][wdbccomp["label"].values==-1]="B"
          wdbccomp["label"][wdbccomp["label"].values==1]="M"
          wdbc_comparation=wdbccomp[["diagnostic","label"]]
          wdbc comparation
```

C:\Users\FedericoDamianEsteba\Anaconda3\lib\site-packages\ipykernel_launcher.
py:10: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: http://pandas.pydata.org/pandas-docs/stable/indexing.html#indexing-view-versus-copy

Remove the CWD from sys.path while we load stuff.

Out[10]:

	diagnostic	label
0	М	В
1	М	М
2	М	М
3	М	В
4	М	В
5	М	М
6	М	М
7	М	М
8	М	М
9	М	В
10	М	М
11	М	М
12	М	В
13	М	М
14	М	М
15	М	М
16	М	М
17	М	М
18	М	В
19	В	М
20	В	М
21	В	М
22	М	В
23	М	В
24	М	В
25	М	В
26	М	М
27	М	М
28	М	М
29	М	М
539	В	В
540	В	М
541	В	М
542	В	М

	diagnostic	label
543	В	М
544	В	М
545	В	М
546	В	М
547	В	М
548	В	М
549	В	М
550	В	М
551	В	М
552	В	М
553	В	М
554	В	М
555	В	М
556	В	М
557	В	В
558	В	М
559	В	М
560	В	М
561	В	В
562	M	В
563	M	В
564	M	В
565	M	В
566	M	М
567	M	В
568	В	В

569 rows × 2 columns

		precision	recall	f1-score	support
	B	0.32	0.10	0.15	357
	M	0.29	0.63	0.40	212
micro	avg	0.30	0.30	0.30	569
macro		0.31	0.37	0.28	569
weighted		0.31	0.30	0.25	569

```
[[ 36 321]
[ 78 134]]
```

SVM

```
In [12]: ocsvm=OneClassSVM(nu=0.25,gamma=0.05)
    ocsvm.fit(wdbc)
    predocsvm=ocsvm.predict(wdbc)
```

```
In [13]: wdbc["labelsvm"]=predocsvm
display(wdbc)
#Muestras anómalas
outlierssvm=wdbc.loc[wdbc["labelsvm"]==-1]
outlierssvm_index=list(outlierssvm.index)
print(outlierssvm_index)

#Número de muestras normales y muestras anómalas
print(wdbc["labelsvm"].value_counts())
```

	mean radius	mean texture	mean perimter	mean area	mean smoothnesss	mean compactness	mean concavity	mean concave points	mear symetry
0	17.990	10.38	122.80	1001.0	0.11840	0.27760	0.300100	0.147100	0.2419
1	20.570	17.77	132.90	1326.0	0.08474	0.07864	0.086900	0.070170	0.1812
2	19.690	21.25	130.00	1203.0	0.10960	0.15990	0.197400	0.127900	0.2069
3	11.420	20.38	77.58	386.1	0.14250	0.28390	0.241400	0.105200	0.2597
4	20.290	14.34	135.10	1297.0	0.10030	0.13280	0.198000	0.104300	0.1809
5	12.450	15.70	82.57	477.1	0.12780	0.17000	0.157800	0.080890	0.2087
6	18.250	19.98	119.60	1040.0	0.09463	0.10900	0.112700	0.074000	0.1794
7	13.710	20.83	90.20	577.9	0.11890	0.16450	0.093660	0.059850	0.2196
8	13.000	21.82	87.50	519.8	0.12730	0.19320	0.185900	0.093530	0.2350
9	12.460	24.04	83.97	475.9	0.11860	0.23960	0.227300	0.085430	0.2030
10	16.020	23.24	102.70	797.8	0.08206	0.06669	0.032990	0.033230	0.1528
11	15.780	17.89	103.60	781.0	0.09710	0.12920	0.099540	0.066060	0.1842
12	19.170	24.80	132.40	1123.0	0.09740	0.24580	0.206500	0.111800	0.2397
13	15.850	23.95	103.70	782.7	0.08401	0.10020	0.099380	0.053640	0.1847
14	13.730	22.61	93.60	578.3	0.11310	0.22930	0.212800	0.080250	0.2069
15	14.540	27.54	96.73	658.8	0.11390	0.15950	0.163900	0.073640	0.2303
16	14.680	20.13	94.74	684.5	0.09867	0.07200	0.073950	0.052590	0.1586
17	16.130	20.68	108.10	798.8	0.11700	0.20220	0.172200	0.102800	0.2164
18	19.810	22.15	130.00	1260.0	0.09831	0.10270	0.147900	0.094980	0.1582
19	13.540	14.36	87.46	566.3	0.09779	0.08129	0.066640	0.047810	0.1885
20	13.080	15.71	85.63	520.0	0.10750	0.12700	0.045680	0.031100	0.1967
21	9.504	12.44	60.34	273.9	0.10240	0.06492	0.029560	0.020760	0.1815
22	15.340	14.26	102.50	704.4	0.10730	0.21350	0.207700	0.097560	0.2521
23	21.160	23.04	137.20	1404.0	0.09428	0.10220	0.109700	0.086320	0.1769
24	16.650	21.38	110.00	904.6	0.11210	0.14570	0.152500	0.091700	0.199ŧ
25	17.140	16.40	116.00	912.7	0.11860	0.22760	0.222900	0.140100	0.3040
26	14.580	21.53	97.41	644.8	0.10540	0.18680	0.142500	0.087830	0.2252
27	18.610	20.25	122.10	1094.0	0.09440	0.10660	0.149000	0.077310	0.1697
28	15.300	25.27	102.40	732.4	0.10820	0.16970	0.168300	0.087510	0.1926
29	17.570	15.05	115.00	955.1	0.09847	0.11570	0.098750	0.079530	0.1739
539	7.691	25.44	48.34	170.4	0.08668	0.11990	0.092520	0.013640	0.2037
540	11.540	14.44	74.65	402.9	0.09984	0.11200	0.067370	0.025940	0.1818
541	14.470	24.99	95.81	656.4	0.08837	0.12300	0.100900	0.038900	0.1872

	mean radius	mean texture	mean perimter	mean area	mean smoothnesss	mean compactness	mean concavity	mean concave points	mear symetry
542	14.740	25.42	94.70	668.6	0.08275	0.07214	0.041050	0.030270	0.1840
543	13.210	28.06	84.88	538.4	0.08671	0.06877	0.029870	0.032750	0.1628
544	13.870	20.70	89.77	584.8	0.09578	0.10180	0.036880	0.023690	0.1620
545	13.620	23.23	87.19	573.2	0.09246	0.06747	0.029740	0.024430	0.1664
546	10.320	16.35	65.31	324.9	0.09434	0.04994	0.010120	0.005495	0.1885
547	10.260	16.58	65.85	320.8	0.08877	0.08066	0.043580	0.024380	0.1669
548	9.683	19.34	61.05	285.7	0.08491	0.05030	0.023370	0.009615	0.1580
549	10.820	24.21	68.89	361.6	0.08192	0.06602	0.015480	0.008160	0.1976
550	10.860	21.48	68.51	360.5	0.07431	0.04227	0.000000	0.000000	0.1661
551	11.130	22.44	71.49	378.4	0.09566	0.08194	0.048240	0.022570	0.2030
552	12.770	29.43	81.35	507.9	0.08276	0.04234	0.019970	0.014990	0.153§
553	9.333	21.94	59.01	264.0	0.09240	0.05605	0.039960	0.012820	0.1692
554	12.880	28.92	82.50	514.3	0.08123	0.05824	0.061950	0.023430	0.1566
555	10.290	27.61	65.67	321.4	0.09030	0.07658	0.059990	0.027380	0.1593
556	10.160	19.59	64.73	311.7	0.10030	0.07504	0.005025	0.011160	0.1791
557	9.423	27.88	59.26	271.3	0.08123	0.04971	0.000000	0.000000	0.1742
558	14.590	22.68	96.39	657.1	0.08473	0.13300	0.102900	0.037360	0.1454
559	11.510	23.93	74.52	403.5	0.09261	0.10210	0.111200	0.041050	0.1388
560	14.050	27.15	91.38	600.4	0.09929	0.11260	0.044620	0.043040	0.1537
561	11.200	29.37	70.67	386.0	0.07449	0.03558	0.000000	0.000000	0.1060
562	15.220	30.62	103.40	716.9	0.10480	0.20870	0.255000	0.094290	0.2128
563	20.920	25.09	143.00	1347.0	0.10990	0.22360	0.317400	0.147400	0.2149
564	21.560	22.39	142.00	1479.0	0.11100	0.11590	0.243900	0.138900	0.1726
565	20.130	28.25	131.20	1261.0	0.09780	0.10340	0.144000	0.097910	0.1752
566	16.600	28.08	108.30	858.1	0.08455	0.10230	0.092510	0.053020	0.1590
567	20.600	29.33	140.10	1265.0	0.11780	0.27700	0.351400	0.152000	0.2397
568	7.760	24.54	47.92	181.0	0.05263	0.04362	0.000000	0.000000	0.1587

569 rows × 30 columns

[0, 3, 11, 12, 13, 14, 15, 17, 20, 23, 24, 25, 26, 29, 31, 32, 33, 34, 35, 3]6, 37, 38, 40, 42, 43, 44, 46, 47, 48, 49, 50, 51, 53, 56, 57, 58, 59, 60, 6 2, 63, 64, 65, 68, 69, 70, 74, 80, 81, 85, 89, 90, 92, 93, 96, 103, 105, 106, 109, 110, 112, 113, 114, 116, 117, 118, 120, 125, 126, 129, 130, 131, 132, 13 4, 136, 138, 142, 143, 145, 148, 150, 152, 153, 156, 157, 158, 159, 160, 161, 162, 164, 165, 167, 168, 171, 172, 174, 175, 177, 178, 183, 184, 186, 187, 19 0, 191, 193, 194, 197, 198, 199, 200, 201, 202, 203, 205, 207, 208, 209, 212, 218, 219, 220, 222, 223, 224, 226, 228, 229, 230, 232, 233, 238, 239, 240, 24 1, 242, 245, 246, 247, 251, 253, 258, 260, 261, 262, 263, 264, 265, 269, 271, 273, 274, 277, 279, 281, 285, 286, 287, 289, 291, 292, 295, 297, 298, 299, 30 5, 306, 308, 309, 310, 311, 312, 313, 318, 320, 322, 327, 330, 331, 332, 336, 338, 339, 341, 343, 346, 350, 355, 357, 358, 359, 360, 361, 362, 363, 364, 36 6, 367, 374, 376, 377, 378, 382, 385, 386, 394, 395, 398, 401, 402, 403, 404, 405, 407, 409, 410, 411, 413, 415, 417, 421, 425, 429, 431, 432, 436, 437, 43 9, 441, 443, 444, 445, 446, 449, 450, 452, 453, 454, 455, 458, 459, 460, 462, 463, 464, 467, 471, 475, 476, 479, 480, 483, 486, 488, 494, 495, 496, 502, 50 3, 508, 510, 513, 515, 516, 517, 521, 522, 525, 526, 533, 535, 536, 538, 545, 546, 548, 549, 550, 551, 552, 553, 554, 555, 559, 561, 563, 564]

-1 287

1 282

Name: labelsvm, dtype: int64

```
In [14]:
         wdbccomp2 = pd.read csv(
              'wdbc.data',
             encoding='utf-8',
             delim whitespace=False,
             names=["id","diagnostic",'mean radius', 'mean texture', 'mean perimter',
          'mean area', 'mean smoothnesss', 'mean compactness', 'mean concavity', 'mean c
         oncave points', 'mean symetry', 'mean fractal dimension', 'se radius', 'se textu
         re', 'se perimter', 'se area', 'se smoothnesss', 'se compactness', 'se concavi
         ty', 'se concave points', 'se symetry', 'se fractal dimension' worst radius',
          'worst texture', 'worst perimter', 'worst area', 'worst smoothnesss', 'worst c
         ompactness', 'worst concavity', 'worst concave points', 'worst symetry', 'worst
         fractal dimension'],
             index col=False,
             header=None,
         )
         wdbccomp2["labelsvm"]=predocsvm
         #for row in wdbccomp2.index:
              if (wdbccomp2["labelsvm"])==-1:
                  wdbccomp2["LabeLsvm"]=["B"]
              if (wdbccomp2["LabeLsvm"])==1:
                  wdbccomp2["LabeLsvm"]=["M"]
         #for row in range(len(wdbccomp2)):
              if wdbccomp2["labelsvm"][row]==-1:
                  wdbccomp2['LabeLsvm'][row]="B"
         #
              elif wdbccomp2["labelsvm"][row]==1:
                  wdbccomp2['labelsvm'][row]="M"
         wdbccomp2["labelsvm"][wdbccomp2["labelsvm"]==-1]="B"
         wdbccomp2["labelsvm"][wdbccomp2["labelsvm"]==1]="M"
         wdbc_comparation2=wdbccomp2[["diagnostic","labelsvm"]]
         display(wdbc comparation2)
```

C:\Users\FedericoDamianEsteba\Anaconda3\lib\site-packages\ipykernel_launcher.
py:24: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: http://pandas.pydata.org/pandas-docs/stable/indexing.html#indexing-view-versus-copy

C:\Users\FedericoDamianEsteba\Anaconda3\lib\site-packages\ipykernel_launcher.
py:25: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: http://pandas.pydata.org/pandas-docs/stable/indexing.html#indexing-view-versus-copy

	diagnostic	labelsvm
0	М	В
1	М	М
2	М	М
3	М	В
4	М	М
5	М	М
6	М	М
7	М	М
8	М	М
9	М	М
10	М	М
11	М	В
12	М	В
13	М	В
14	М	В
15	М	В
16	М	М
17	М	В
18	М	М
19	В	М
20	В	В
21	В	М
22	М	М
23	M	В
24	М	В
25	M	В
26	М	В
27	М	М
28	М	М
29	M	В
539	В	М
540	В	М
541	В	М
542	В	М

	diagnostic	labelsvm
543	В	М
544	В	М
545	В	В
546	В	В
547	В	М
548	В	В
549	В	В
550	В	В
551	В	В
552	В	В
553	В	В
554	В	В
555	В	В
556	В	M
557	В	M
558	В	M
559	В	В
560	В	M
561	В	В
562	М	M
563	М	В
564	М	В
565	М	M
566	М	M
567	М	M
568	В	M

569 rows × 2 columns

	precision	recall	f1-score	support	
B	0.63	0.51	0.57	357	
M	0.38	0.50	0.43	212	
micro avg	0.51	0.51	0.51	569	
macro avg	0.51	0.51	0.50	569	
weighted avg	0.54	0.51	0.52	569	
[[182 175] [105 107]]					

Test DBSCAN

Conlcusion

Hay diferentes tipos de métodos para separar muestras anómalas basaados en agrupamientos y denssidades como DBSCAN. Pero también otros como Isolation Forest y OneClassSVM derivado de las técnicas de árboles y SVM.

Es todavía un desafío saber que algoritmo es el más óptimo para detectar los distintos tipos de anomalías.